



# 연합학습 기반 항공기 엔진 RUL 예측

---

오전 8팀 | 2025. 11. 28

20211886 이기민   20211867 강한성

## | 발표 목차 (Table of Contents)

### 1. 서론 (Why)

예지 보전의 중요성  
데이터 저장 문제  
연구 목표

### 2. 이론 (What)

연합학습의 개념  
Non-IID 데이터  
FedAvg / Prox / MA

### 3. 구현 (How)

CMAPSS 데이터셋  
데이터 전처리 (PCA)  
모델 아키텍처

### 4. 결과 (Result)

성능 비교 실험  
그래프 분석  
결론 및 제언

# | RUL (잔존 유효 수명) 예측의 필요성

## 1. 경제적 손실 방지

- 항공기 엔진 고장은 막대한 지연 보상금과 수리비를 초래합니다.
- 부품을 너무 일찍 교체하는 '과잉 정비' 비용을 줄일 수 있습니다.

## 2. 절대적 안전 확보

- 엔진 결함은 대형 인명 사고로 직결됩니다.
- 사후 대응(Corrective)이 아닌 사전 예측(Prognostics)이 필수적입니다.

"언제 고장날지 미리 알 수 있다면?"

Just-in-Time Maintenance 실현

## | 기존 방식의 한계와 연합학습의 도입

### 기존 중앙집중형 학습 (Centralized)

- 모든 데이터를 하나의 서버로 모아야 함
- **데이터 프라이버시 문제:** 항공사/제조사 간 민감한 설비 데이터 공유 불가
- **네트워크 비용:** 방대한 센서 데이터 전송 부담

### 연합 학습 (Federated Learning)

- 데이터는 각 로컬 기기(Edge)에 남김
- **가중치(Weight)만 공유:** 보안 유지
- 다양한 환경의 데이터를 간접적으로 학습하여 모델의 일반화 성능 향상

## | 연합학습의 핵심 과제: Non-IID 데이터

**IID (Independent and Identically Distributed):** 모든 데이터가 이상적으로 고르게 분포됨

**Non-IID:** 현실 세계의 데이터는 클라이언트마다 분포가 제각각임



**항공사 A**

단거리 운항 위주  
(이착륙 잦음)



**항공사 B**

장거리 운항 위주  
(순항 시간 김)



**문제점**

단순 평균(FedAvg) 시  
모델 성능 저하 발생

## 해결 전략: 고급 FL 알고리즘 비교

### FedAvg

**기본 알고리즘:** 로컬 가중치의 단순 평균 (Weighted Average)

한계: 데이터 분포 차이가 크면 글로벌 모델이 수렴하지 않을 수 있음.

### FedProx

**규제 기반 (Proximal Term):** 로컬 업데이트 시 글로벌 모델과 너무 멀어지지 않도록 제약

효과: 스트래글러(느린 기기)와 Non-IID 환경에서 안정적임.

### FedMA

**매칭 기반 (Matched Averaging):** 레이어별 뉴런을 매칭하여 통합

효과: 단순 평균보다 훨씬 정교하게 지식을 통합하여 최고의 성능 달성 가능.

# 데이터셋 소개: NASA C-MAPSS FD004

## 왜 FD004인가?

- C-MAPSS 데이터셋 중 가장 난이도가 높음
- 6가지 작동 조건(Operating Conditions)이 섞여 있음
- 2가지 복합 고장 모드(HPC, Fan) 포함

데이터셋	작동 조건	고장 모드	Test 엔진 수
FD001	1개	1개	100
<b>FD004</b>	<b>6개</b>	<b>2개</b>	<b>248</b>



[Image of Jet Engine Diagram]

21개의 센서 데이터가 시계열로 제공됨.

# | 데이터 전처리 파이프라인 (Preprocessing)

## 1. 정규화

(Normalization)

---

Min-Max Scaling을 통해 모든 센서 값을 0~1 사이로 변환하여 모델 학습 안정화

## 2. 윈도우 슬라이싱

(Sliding Window)

---

시계열 특성을 반영하기 위해 연속된 데이터를 묶음 (Window Size: 30)

## 3. 차원 축소 (PCA)

(Principal Component Analysis)

---

**핵심 전략:** 노이즈가 많은 21개 센서 데이터를 **3개의 주성분**으로 압축하여 학습 효율 증대



## | 실험 환경 및 하이퍼파라미터

### System Specs

- **Language:** Python 3.12.12
- **Framework:**
  - TensorFlow: 2.19.0    • Keras: 3.10.0    • NumPy: 2.0.2
  - Pandas: 2.2.2    • Scikit-learn: 1.6.1    • SciPy: 1.16.3
  - Matplotlib: 3.10.0    • Seaborn: 0.13.2
- **Hardware:** Tesla T4 15GiB


### Federated Settings

- **Clients:** 3개 (가상 클라이언트)
- **Communication Rounds:** 5회
- **Local Epochs:** 30회

하이퍼파라미터	Value
Batch Size	32
학습률	0.01
옵티마이저	Adam
손실 함수	MSE (Mean Squared Error)
<b>PCA Components</b>	<b>3</b>

## 결과 1: 중앙집중형 학습 (Baseline)

연합학습 성능의 기준점이 되는 '이상적인(Ideal)' 환경의 결과입니다.



### Centralized Performance

- **RMSE:** 39.52
- **R<sup>2</sup> Score:** 0.425
- **특징:** 모든 데이터를 한곳에서 학습했기 때문에 오차가 가장 낮음. (Lower Bound)

## 결과 2: 알고리즘별 성능 비교

Centralized **39.52**



FedAvg **41.60**



FedProx **40.17**



FedMA **39.82**



\* RMSE (낮을수록 좋음)

### 결과 분석

- **FedAvg**: 가장 높은 오차(41.60)를 보임. Non-IID 데이터 분포에 취약함.
- **FedProx**: 규제항 덕분에 FedAvg 대비 약 3.5% 성능 개선.
- **FedMA**: **중앙집중형에 가장 근접(39.82)**한 성능 달성. 복잡한 신경망 구조를 효과적으로 매칭함.

## | 추가 분석: PCA 적용 효과 (Ablation Study)

### Without PCA (원본 데이터)

센서 데이터의 노이즈가 그대로 학습됨

**RMSE: 43.49**

예측 그래프가 매우 불안정함

### With PCA (3 Components)

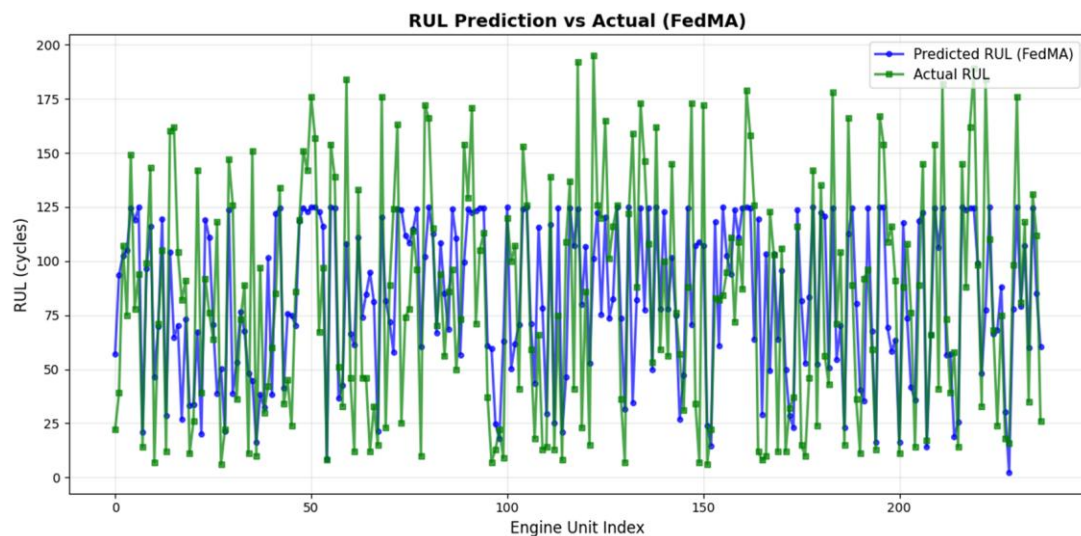
주요 특징만 추출하여 노이즈 제거

**RMSE: 39.52**

성능 약 17% 향상

결론: 복잡한 센서 데이터(FD004)에서는 차원 축소가 필수적임을 확인.

## 최종 예측 결과 시각화 (FedMA)



### Matched Averaging Performance

- RMSE: 39.82
- $R^2$  Score: 0.407

### 그래프 해석

- **X축:** 엔진 유닛 인덱스 / **Y축:** 잔존 수명(RUL)
- **초록색 점:** 실제 정답값 (Ground Truth)
- **파란색 점:** FedMA 모델의 예측값
- RUL 값이 낮은 구간을 잘 따라잡지 못하고 있으나, 클리핑한 125를 넘지 않는 구간 안에서 125를 넘긴 구간의 추세를 따라가려는 모습을 보여주고 있음



## | 결론 및 향후 연구 과제

### 연구 결론

연합학습(FedMA)과 차원 축소(PCA)를 결합하여, 데이터 유출 없이도 중앙집중형에 버금가는 RUL 예측 성능을 확보했습니다.

### 향후 과제 (Future Work)

- 통신 효율성: FedMA의 높은 통신 비용을 줄이기 위한 경량화 연구 필요
- 이질적 모델: 클라이언트마다 다른 모델 구조를 가지는 환경에서의 FL 연구 필요